

Klasifikasi Objek Langit Berdasarkan Data Fotometri SDSS Menggunakan Machine Learning

Oleh Wa Ode Nisrina Sayyidah Hidayat

A. Latar Belakang

Pemetaan alam semesta modern, seperti yang dilakukan oleh Sloan Digital Sky Survey (SDSS), menghasilkan volume data observasi yang masif hingga jutaan objek langit per malam. Secara historis, klasifikasi objek langit menjadi Bintang, Galaksi, atau Quasar dilakukan melalui analisis spektroskopi untuk mendapatkan nilai redshift (pergeseran merah). Namun, pengambilan data spektrum memakan biaya komputasi instrumen yang mahal dan waktu observasi yang lama.

Sebagai alternatif, teleskop modern dapat secara cepat dan ekonomis memperoleh citra objek melalui filter fotometri yang meliputi pita ultraviolet, hijau, merah, near-infrared, dan infrared (u, g, r, i, z). Kesenjangan antara metode spektroskopi yang mahal dan fotometri yang efisien menimbulkan kebutuhan mendesak akan model prediktif yang mampu mengklasifikasikan objek langit dengan akurat hanya menggunakan data fotometri. Proyek ini dibangun atas premis bahwa Machine Learning dapat menggantikan peran spektroskopi awal dalam klasifikasi, sehingga mengurangi risiko data leakage yang sering terjadi apabila redshift digunakan sebagai fitur prediktif.

B. Rumusan Masalah

Berdasarkan latar belakang tersebut, permasalahan dapat dirumuskan sebagai berikut:

1. Bagaimana membangun model klasifikasi berbasis Machine Learning yang valid secara ilmiah untuk membedakan Bintang, Galaksi, dan Quasar tanpa memanfaatkan variabel redshift maupun metadata teleskop?
2. Sejauh mana kontribusi rekayasa fitur parametrik, khususnya indeks warna astronomi (u-g, g-r, r-i, i-z), dalam meningkatkan kemampuan diskriminatif algoritma dibandingkan penggunaan magnitudo absolut saja?
3. Bagaimana algoritma berbasis Tree Ensemble (misalnya XGBoost dan Random Forest) dapat menangani ketidakseimbangan kelas alami di alam semesta, di mana populasi Quasar relatif langka dibandingkan Bintang dan Galaksi, agar hasil evaluasi (confusion matrix) tidak bias terhadap kelas mayoritas?

C. Tujuan

Tujuan dari dilakukannya proyek ini yaitu:

1. Mengembangkan arsitektur klasifikasi yang independen terhadap redshift, memaksa model untuk belajar murni dari profil fotometri objek langit.
2. Melakukan kuantifikasi Feature Importance, dengan membuktikan secara statistik interaksi antar filter cahaya (misalnya u-g vs i-z) yang menjadi pemisah keputusan

- terkuat antar kelas, sehingga mendukung validasi teori astrofisika melalui bukti data-driven.
3. Mengoptimalkan evaluasi kelas minoritas, Quasar dan Bintang, sehingga model memiliki sensitivitas dan reliabilitas tinggi dalam mendeteksi objek langka, bukan hanya kelas mayoritas yaitu Galaksi.
 4. Membandingkan model Logistic Regression, Random Forest, dan XGBoost dalam memprediksi klasifikasi melalui metrik recall dan F1-score.

D. Informasi Dataset

Sumber dataset

kaggle.com/datasets/fedesoriano/stellar-classification-dataset-sdss17

Ukuran

100,000 baris observasi

Variabel yang digunakan

- u : Magnitudo di pita ultraviolet
- g : Magnitudo di pita hijau
- r : Magnitudo di pita merah
- i : Magnitudo di pita near-infrared
- z : Magnitudo di pita infrared
- class : Variabel target


Tipe Data

- Numerik : u, g, r, i, z (magnitudo fotometrik)
- Kategorikal : class (GALAXY, STAR, QUASAR)

Sitasi

fedesoriano. (January 2022). Stellar Classification Dataset - SDSS17

E. Alur Pengerjaan Proyek



Proyek dilakukan dengan 2 tools berbeda:

- Pembangunan model dengan Jupyter Notebook
- Deployment dengan streamlit

F. Pembahasan


1. Data Understanding

Pada proses ini mencakup load dataset, pengambilan subset data hanya 6 variabel, melihat statistik deskriptif, penanganan *outlier* pada kolom *u*, *g*, *z* Dimana ditemukan adanya nilai -999. Outputnya berupa data yang telah bersih dengan ukuran akhir 99.999 baris observasi dan 6 kolom.


2. EDA

Pada proses ini dilakukan beberapa visualisasi untuk melihat karakteristik data.


- Barchart Distribusi Kelas Target



- Pairplot Magnitudo Fotometri



- Histogram dan Boxplot Magnitudo Fotometri



Beberapa temuan utama dari hasil EDA diatas yakni:

- Target Class sangat *imbalanced* dengan jumlah Quasar adalah yang terkecil sebesar 18.961, sedangkan Galaxy adalah yang terbanyak yaitu 59.445. Dari hasil ini perlu dilakukan pembandingan antara model, dengan asumsi bahwa model linear seperti Logistic Regression tidaklah cocok.
- Dari pairplot terlihat bahwa kelas target tersebar tidak merata/berkumpul di suatu area pada seluruh variabel numerik. Sehingga tidak terlihat adanya klasifikasi yang jelas secara visual. Lalu, ditemukan juga adanya pola yang aneh di sekitar angka 25, yakni membentuk suatu garis lurus. Dalam konteks astronomi ini bisa diakibatkan oleh:
 - a. Saturation / Detection Limit : Instrumen teleskop memiliki, batas sensitivitas, noise floor, clipping magnitude. Objek sangat terang atau sangat redup bisa “menumpuk” pada rentang tertentu.
 - b. Quantization Magnitude: pembulatan nilai magnitudo, discretization kecil akibat preprocessing pipeline.
 - c. Selection Bias SDSS: target selection tertentu, magnitude cut-off. Akibatnya distribusi objek tidak benar-benar natural.

Penanganannya adalah berupa memberikan variabel *flag* agar model tahu bahwa angka berulang berasal dari nilai maksimum teleskop.

- Dari visualisasi di atas, terlihat distribusinya bimodal atau terdapat 2 puncak. Selain itu, ada banyak outlier. Namun dalam konteks astronomi, titik-titik ekstrem tersebut bisa jadi adalah objek dengan luminositas sangat tinggi atau bintang kerdil yang sangat redup. Adapun boxplot Quasar cenderung sedikit lebih sempit dan lebih padat dibandingkan yang lain, namun sebarannya (whiskers dan outliers) sangat panjang. Ini mencerminkan sifat astrofisika Quasar yang memiliki pancaran energi sangat ekstrem dan bervariasi.

3. Feature Engineering

Proses ini untuk melanjutkan temuan dari proses EDA dimana seluruh fitur saling tumpang tindih dan adanya anomali nilai ambang maksimum teleskop. Fitur baru yang dibuat adalah:

a. Flag Ambang Batas (*u_limit_flag* dan *r_limit_flag*)

Fitur ini sebagai penangan lebih lanjut untuk data anomali berupa nilai-nilai membentuk garis vertical, yakni dengan melabeli nilai tersebut dengan flag agar model tahu bahwa nilai tersebut dekat dengan ambang teleskop.

b. Mengekstrak Selisih Warna (*u-g*, *g-r*, *r-i*, *i-z*)

Filter SDSS tersusun berurutan berdasarkan panjang gelombang:

$u \rightarrow g \rightarrow r \rightarrow i \rightarrow z$

dari ultraviolet, visible, near infrared

Masing-masing band menangkap bagian spektrum yang saling berdekatan.

Fitur ini bertujuan memberi sinyal bahwa masing-masing objek memiliki spektrum berbeda.

c. PCA Components (*PC1*, *PC2*, *PC3*)

Indeks warna (*u-g*, *g-r*, dll.) masih memiliki korelasi linear terselubung karena mereka berbagi variabel yang sama (misalnya, *g* ada di *u-g* dan *g-r*). PCA akan mengekstrak variansi terbesar dari kombinasi warna ini dan mentransformasikannya menjadi sumbu baru yang ortogonal (sama sekali tidak berkorelasi).

d. Distance from Stellar Locus (*dist_locus*)


Di alam semesta, bintang-bintang (STAR) memiliki karakteristik radiasi benda hitam yang teratur. Ketika diplot dalam color-color diagram (misalnya *u-g* vs *g-r*), bintang tidak tersebar acak, melainkan berkumpul membentuk jalur melengkung yang sangat spesifik dan sempit yang disebut Stellar Locus. Sementara itu, Quasar (QSO) dan Galaksi (GALAXY) tersebar acak jauh di luar jalur tersebut.

4. Modelling dan Evaluation

Tahap Modelling menggunakan 3 jenis model yaitu Logistic Regression, Random Forest, dan XGBoost. Selanjutnya masing-masing model dibandingkan dengan hasil evaluasinya yaitu *accuracy*, dan *macro f1*.


Hasil evaluasi:

Jenis Model	F1 Macro	F1 Weighted	Recall Macro	Recall Weighted
Logistic Regression	0.6706	0.7362	0.6724	0.7587
Random Forest	0.8511	0.8825	0.8414	0.8841
XGBoost	0.8541	0.8853	0.8458	0.8866



Hasilnya model XGBoost adalah yang menghasilkan evaluasi tertinggi di berbagai metrik, sehingga model yang digunakan dalam dashboard adalah XGBoost.

Adapun untuk Feature Importance yakni:



Terlihat bahwa variabel dengan peran terbesar dalam menjelaskan klasifikasi kelas target adalah *r-i*, *g-r*, dan *PC1*.

5. Deployment

a. Link Dashboard

<https://sdss-astronomy-classification-f4raxkaqmckuav3hhw2jnt.streamlit.app/>

b. Tampilan Dashboard

